Конспект по теме "Метрики регрессии"

Коэффициент детерминации

Коэффициент детерминации, или **метрика R2**, вычисляет долю среднеквадратичной ошибки модели от *MSE* среднего, а затем вычитает эту величину из единицы. Увеличение метрики означает прирост качества модели.

Формула расчёта *R2* выглядит так:

- Значение метрики *R2* равно единице только в одном случае, если *MSE* нулевое. Такая модель предсказывает все ответы идеально.
- *R2* равно нулю: модель работает так же, как и среднее.
- Если метрика *R2* отрицательна, качество модели очень низкое.
- Значения *R2* больше единицы быть не может.

В библиотеке *sklearn.metrics* есть функция для подсчёта этой метрики — *r2_score()*:

```
from sklearn.metrics import r2_score

print("R2 =", r2_score(target, predicted))
```

Среднее абсолютное отклонение

Дадим общепринятые в *Data Science* обозначения:

$$y_i$$

- Значение целевого признака для объекта с порядковым номером ***i*** в выборке, на которой измеряется качество. Нижний индекс показывает номер объекта.

$$\hat{y}_i$$

- Значение предсказания для объекта с порядковым номером ***i***, например, в тестовой выборке.

Ещё одна метрика качества — **MAE** (*mean absolute error*). Она похожа на *MSE*, но в ней нет возведения в квадрат. Запишем метрику в обозначениях, принятых в Data Science.

Отклонение объекта:

$$\text{Отклонение} = y_i - \hat{y}_i$$

Чтобы в новой метрике избавиться от разницы между недооценкой и переоценкой, вычисляется **абсолютное отклонение**. Это модуль от отклонения:

$$\text{Абсолютное отклонение} = |y_i - \hat{y}_i|$$

Чтобы собрать отклонения по всей выборке, дополним обозначения:

$$N$$

- Количество объектов в выборке.

$$\sum_{i=1}^{N}$$

- Суммирование по всем объектам выборки (***i*** меняется от 1 до *N*).

Формула **среднего абсолютного отклонения**, или **MAE:**

$$MAE = \frac{1}{N}\sum_{i=1}^{N}\left|y_i - \hat{y}_i\right|$$

В библиотеке *sklearn.metrics* есть функция для подсчёта этой метрики — *mean_absolute_error()*:

```
from sklearn.metrics import mean_absolute_error

mae = mean_absolute_error(target, predicted))
```

Чтобы рассчитать *MSE*, за константу мы принимали среднее значение.

Константная модель выбирается так, чтобы значение метрики *MAE* было предельно низким. Нужно найти такое значение ***a***, при котором достигается минимум:

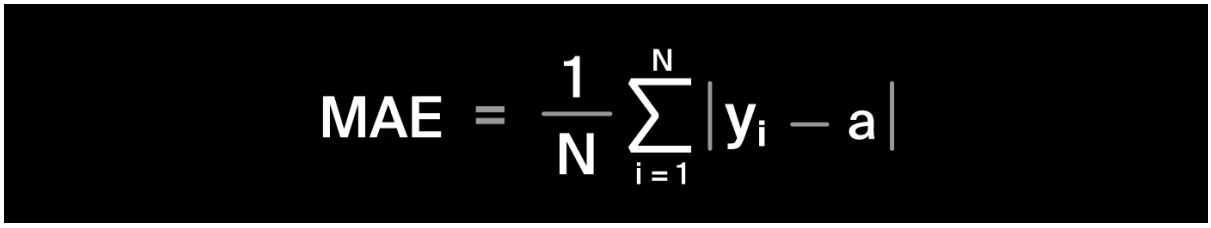

$$MAE = \frac{1}{N}\sum_{i=1}^{N}|y_i - a|$$

Минимум получается, когда ***a*** равно медиане целевого признака.

В отличие от *MAE*, метрика *RMSE* **чувствительнее к большим значениям:** значимые ошибки сильно влияют на итоговое значение квадратного корня из среднеквадратичной ошибки. Таким образом, можно менять значение *RMSE,* не меняя значения *MAE*.