Конспект по теме «Свёрточные сети»

Свёртка

Полносвязные сети не могут работать с большими изображениями: если нейронов мало, сеть не найдёт зависимостей, а если много — переобучится. Эту проблему решает свёртка.

Чтобы найти важные для классификации элементы, **свёртка** (англ. *convolution*) ко всем пикселям применяет одинаковые операции.

Разберём, что такое **одномерная свёртка** (англ. *one-dimensional convolution)*. Поскольку одномерных изображений не бывает, рассмотрим эту операцию на примере последовательностей.

Пусть *w* (англ. *weight*) — это веса, *s* (англ. *sequence*) — последовательность.

Свёртка (*c*) выполняется так: веса (*w*) «ползут» вдоль последовательности (*s*), а в каждой позиции вычисляется скалярное произведение. Причём длина вектора весов *n* всегда не больше длины вектора последовательности *m*. Иначе не будет ни одной позиции, к которой можно применить свёртку.

Запишем операцию одномерной свёртки формулой:

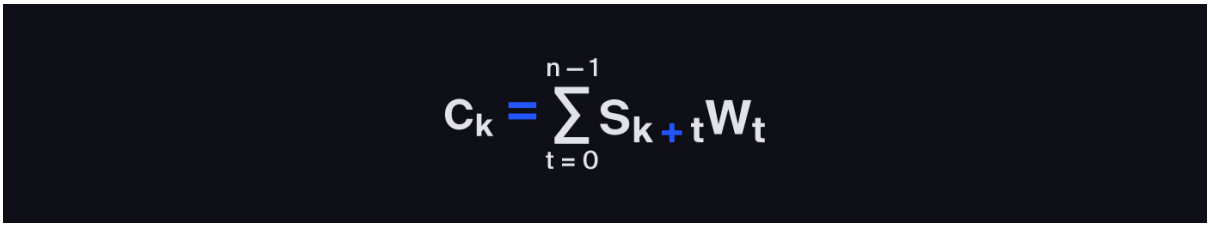

где *t* — индекс для вычисления скалярного произведения, *k* — любое значение от 0 до (m - n + 1).

Число (m - n + 1) выбрано так, чтобы веса не выходили за пределы последовательности *s*.

Напишем одномерную свёртку на Python:

```
def convolve(sequence, weights):
    convolution = np.zeros(len(sequence) - len(weights) + 1)
    for i in range(convolution.shape[0]):
        convolution[i] = np.sum(weights * sequence[i:i + len(weights)])
```

Теперь посмотрим, как работает **двумерная свёртка** (англ. *two-dimensional convolution, 2D convolution*). Возьмём двумерное изображение *s* размером *m×m* пикселей и матрицу весов *w* размером *n×n* пикселей. Эту матрицу называют **ядром свёртки** (англ. *kernel*).

Ядро двигается по изображению слева направо и сверху вниз. В каждой позиции её веса умножаются поэлементно на пиксели, полученные произведения суммируются и записываются как пиксели результата.

Для примера свернём такие матрицы:

```
s = [[1, 1, 1, 0, 0],
     [0, 1, 1, 1, 0],
     [0, 0, 1, 1, 1],
     [0, 0, 1, 1, 0],
     [0, 1, 1, 0, 0]]

w = [[1, 0, 1],
     [0, 1, 0],
     [1, 0, 1]]
```

Запишем двумерную свёртку формулой:

$$C_{k1,\,k2} = \sum_{t_1=0}^{n} \sum_{t_2=0}^{n} S_{k1+t1,\,k2+t2} W_{t1,\,t2}$$

Операцией свёртки можно найти контуры изображения. Горизонтальные контуры можно найти свёрткой с таким ядром:

```
np.array([[-1, -2, -1],
          [ 0,  0,  0],
          [ 1,  2,  1]])
```

Это ядро эмпирически вывели американские учёные Ирвин Собель и Гари Фельдман для поиска контуров изображения. Оно выделяет контуры лучше, чем рассмотренное в начале урока ядро.

Чтобы найти вертикальные контуры, применим такое ядро:

```
np.array([[-1, 0, 1],
          [-2, 0, 2],
          [-1, 0, 1]])
```

Свёрточный слой

Разберём, что такое свёрточные слои и какую они роль играют в **свёрточных нейросетях** (англ. *convolutional neural network, CNN*). **Свёрточные слои** (англ. *convolution layers*) применяют операцию свёртки к входным изображениям. Они выполняют бóльшую часть вычислительной работы сети.

Свёрточный слой состоит из настраиваемых и обучаемых **фильтров** (англ. *filter*) — наборов весов, которые применяются к изображению. По сути это квадратная матрица размером *K×K* (от слова *kernel*) пикселей.

Если изображение цветное, к фильтру добавляется ещё и **глубина** (англ. *depth*), то есть третье измерение. И тогда фильтр уже не матрица, а тензор, или многомерная таблица.

Рассмотрим пример. Перед вами три канала: красный, синий, зелёный. Фильтр размером 3x3x3 (три пикселя по ширине, высоте и глубине) последовательно скользит по входному изображению в каждом канале, выполняя операцию свёртки. По третьему измерению он не двигается. Для разных цветов веса разные. Полученные изображения поэлементно складываются, образуя результат свёртки.

Фильтров в свёрточном слое может быть несколько. Каждый фильтр возвращает двумерное изображение, из которого можно снова сделать трёхмерное. На следующем свёрточном слое глубина фильтров равна числу фильтров на предыдущем слое.

Знак звёздочки (*) означает операцию свёртки.

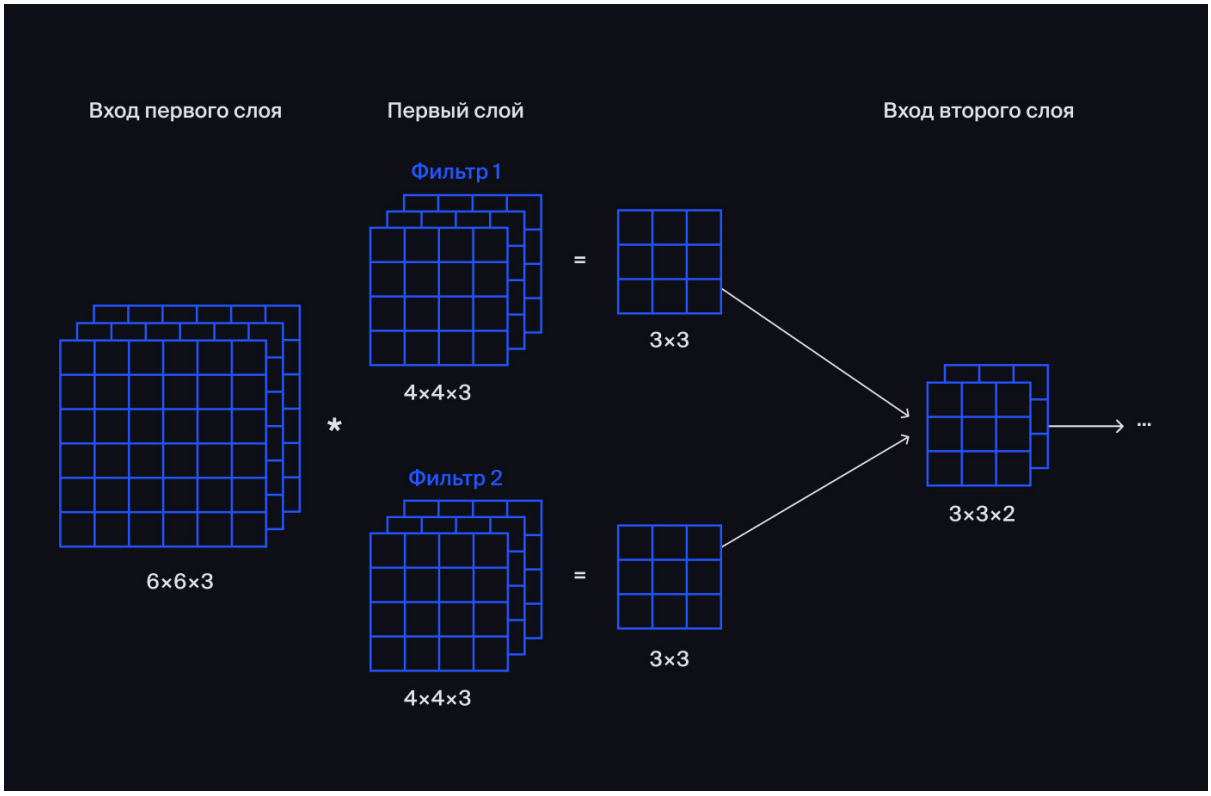

Параметров в свёрточных слоях намного меньше, чем в полносвязных. Значит, свёрточные слои легче обучать.

Рассмотрим настройки свёрточного слоя:

1. **Padding** (англ. «отбивка»). Эта техника добавляет к краям матрицы нули (англ. *zero padding*), чтобы крайние пиксели участвовали в свёртке не меньше раз, чем центральные. Так важная информация в изображении потеряна не будет. Добавленные нули также участвуют в свёртке. Величина паддинга задаёт толщину отбивки из нулей.

2. **Striding**, или **Stride** (англ. «большой шаг»). Эта техника сдвигает фильтр не на один пиксель, а на бóльшее количество пикселей. Она применяется, когда нужно получить выходное изображение меньшего размера.

Вычислим размер выходного тензора после свёрточного слоя. Если у начального изображения размером *W×W×D* (от слов *depth)* есть фильтр *K×K×D*, паддинг (*P*) и шаг (*S*), то новый размер изображения *W'* вычисляется по формуле:

$$W' = \frac{(W - K + 2P)}{S} + 1$$

Чтобы лучше усвоить, как работают свёртки с разными параметрами, попробуйте этот визуализатор на GitHub.

Свёрточные слои Keras

Создадим свёрточный слой **Conv2D** (от англ. *two-dimensonal convolution*):

```
keras.layers.Conv2D(filters, kernel_size, strides, padding, activation)
```

Разберём все параметры:

- **filters** — количество фильтров, которому равна величина выходного тензора.
- **kernel_size** (англ. «размер ядра свёртки») — пространственный размер фильтра *K*. Повторим, фильтр — это тензор размером *K×K×D,* где *D* равна глубине входного изображения.
- **strides** — размер шага свёртки. По умолчанию величина *strides* равна единице.
- **padding** — толщина отбивки из нулей. Есть два типа паддинга: *valid* (англ. «допустимый») и *same* (англ. «одинаковый»). Тип паддинга по умолчанию — *valid*, то есть нулевой. Тип *same* означает автоматический подбор величины паддинга так, чтобы ширина и высота выходного тензора была равна ширине и высоте входного тензора.
- **activation** — активация, которую применяют сразу же после свёртки с фильтром. Можно указать знакомые вам функции активации: `'relu'` и `'sigmoid'`. По умолчанию этот параметр равен *None*, то есть активация отключена.

Чтобы результаты свёрточного слоя можно было передать полносвязному слою, подключим новый слой **Flatten** (англ. «разглаживать»). Он делает многомерный тензор одномерным.

Например, после входного изображения размером 32×32×3 идёт свёрточный слой, а потом — полносвязный. Между ними нужно вставить слой *Flatten*:

```
from tensorflow.keras import Sequential
from tensorflow.keras.layers import Conv2D, Flatten, Dense


model = Sequential()

# здесь у тензора размер (None, 32, 32, 3)
# первая размерность отвечает за разные объекты
# она равна None, потому что размер батча ещё не известен

model.add(Conv2D(filters=4, kernel_size=(3, 3), input_shape=(32, 32, 3)))

# здесь у тензора размер (None, 30, 30, 4)
```

```
model.add(Flatten())

# здесь у тензора размер (None, 3600)
# где 3600 = 30 * 30 * 4

model.add(Dense(...))
```

Архитектура LeNet

Уменьшить количество параметров модели можно техникой **пулинга** (англ. *pooling*, «объединение»). Технику рассмотрим на примере **Max Pooling** (англ. «максимальный пулинг»):

1. Выбирается размер ядра, например, 2x2;

2. Ядро начинает двигаться слева направо и сверху вниз, в каждом окне из четырёх пикселей находится пиксель с максимальным значением;

3. Пиксель с максимальным значением остаётся, его ближайшие соседи исчезают;

4. Получаем матрицу, состоящую только из пикселей с максимальными значениями.

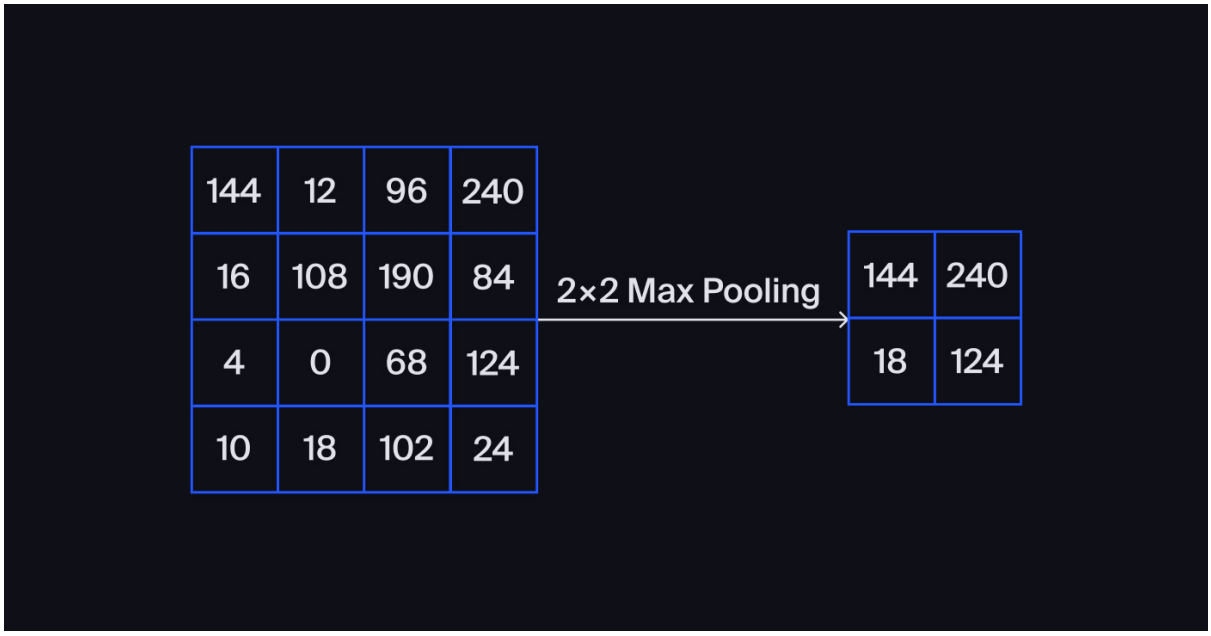

В *Keras* можно выполнить не только операцию *MaxPooling*, но и **AveragePooling** (англ. «средний пулинг»). Разберём, в чём их разница:

- *MaxPooling* возвращает максимальное внутри канала значение пикселя из группы. Если у входного изображения размер *W×W*, то у выходного изображения размер будет *W/K*, где *K* — размер ядра.
- *AveragePooling* возвращает среднее значение из группы пикселей внутри канала.

Рассмотрим запись операции *AveragePooling* в *Keras*:

```
keras.layers.AveragePooling2D(pool_size=(2, 2), strides=None, padding='valid', ...)
```

Разберём каждый параметр:

- **pool_size** — размер пулинга: чем он больше, тем шире охват задействованных соседних пикселей.
- **strides** — величина шага. Если указано *None*, то шаг равен размеру пулинга.
- **padding** — толщина отбивки из нулей. Тип паддинга *valid* означает нулевой (по умолчанию), тип *same* — автоматический подбор величины паддинга.

Параметры *MaxPooling2D* аналогичны этим параметрам.

Теперь инструментов достаточно, чтобы построить популярную архитектуру для классификации изображений размером 20–30 пикселей — **LeNet**. Название сети произошло от имени её создателя Яна Лекуна (*Yann André LeCun*), разработчика технологии сжатия изображений *DjVu*, главы лаборатории искусственного интеллекта *Facebook*.

LeNet строится так:

1. Сеть начинается с 2–3 свёрточных слоёв размером 5×5, чередующихся с *Average Pooling* размером 2×2. Постепенно они уменьшают пространственное разрешение и собирают разбросанную по всему изображению информацию в матрицы маленького размера (около 5 пикселей).
2. Чтобы не потерять важную информацию, количество фильтров растёт от слоя к слою.

3. В конце сети идёт 1–2 полносвязных слоя, которые собирают все признаки и классифицируют их.

Реализация LeNet на Keras:

```
model = Sequential()

model.add(Conv2D(6, (5, 5), padding='same', activation='tanh',
                 input_shape=(28, 28, 1)))
model.add(AvgPool2D(pool_size=(2, 2)))

model.add(Conv2D(16, (5, 5), padding='valid', activation='tanh'))
model.add(AvgPool2D(pool_size=(2, 2)))

model.add(Flatten())
model.add(Dense(120, activation='tanh'))

model.add(Dense(84, activation='tanh'))

model.add(Dense(10, activation='softmax'))

model.compile(loss='sparse_categorical_crossentropy', optimizer='sgd', metrics=['acc'])
model.summary()
```

Алгоритм Adam

Градиентный спуск (*SGD*) — это не самый оптимальный алгоритм обучения нейронной сети. Если величина шага слишком маленькая, сеть будет обучаться долго, а если большая — может пропустить минимум. Чтобы подбор шага был автоматическим, применяют алгоритм **Adam** (от англ. *adaptive moment estimation,* «адаптивность на основе оценки моментов»). Он подбирает различные параметры для разных нейронов, что также ускоряет обучение модели.

Чтобы понять, как этот алгоритм работает, рассмотрим визуализацию Эмильена Дюпона из Оксфордского университета. В ней четыре алгоритма: слева *SGD*, справа *Adam*, а между ними — два похожих на *Adam* алгоритма (их разбирать не будем). Быстрее всех минимум находит *Adam*.

Запишем алгоритм *Adam* в *Keras*:

```
model.compile(optimizer='adam', loss='sparse_categorical_crossentropy',
              metrics=['acc'])
```

Чтобы настроить гиперпараметры, подключим класс алгоритма:

```
from tensorflow.keras.optimizers import Adam
optimizer = Adam()

model.compile(optimizer=optimizer, loss='sparse_categorical_crossentropy',
              metrics=['acc'])
```

Основной настраиваемый гиперпараметр в алгоритме *Adam* — скорость обучения (*learning rate*). Это шаг градиентного спуска, с которого алгоритм стартует. Записывается так:

```
optimizer = Adam(lr=0.01)
```

По умолчанию он равен 0.001. Уменьшение шага иногда может замедлить обучение, но улучшить итоговое качество модели.

Загрузчики данных

Массивы хранятся не на жёстком диске компьютера, а только в оперативной памяти. Представьте, нужно сделать массив из терабайта изображений. Даже представить такое сложно, не то что выполнить… Ресурсы оперативной памяти не безграничны!

Чтобы справиться с таким объёмом изображений, к работе подключают динамическую загрузку данных.

В библиотеке *Keras* есть удобный загрузчик **ImageDataGenerator** (англ. «генератор данных изображений»):

```
from tensorflow.keras.preprocessing.image import ImageDataGenerator
```

Из фотографий в папках класс *ImageDataGenerator* формирует батчи с изображениями и метками классов. Создадим его:

```
# от англ. data generator
datagen = ImageDataGenerator()
```

Чтобы загрузчик извлёк данные из папки, вызовем функцию **flow_from_directory()** (англ. «поток из директории»):

```
datagen_flow = datagen.flow_from_directory(
    # папка, в которой хранится датасет
    '/dataset/',
    # к какому размеру приводить изображения
    target_size=(150, 150),
    # размер батча
    batch_size=16,
    # в каком виде выдавать метки классов
    class_mode='sparse',
    # фиксируем генератор случайных чисел (от англ. random seed)
    seed=12345)
```

```
Found 1683 images belonging to 12 classes.
```

Загрузчик нашёл 12 классов (папок), всего в них 1683 изображений.

Поясним некоторые аргументы:

- `target_size=(150, 150)` — аргумент с шириной и высотой, к которым будут приводиться изображения. В папках могут лежать изображения разного размера, а нейронным сетям нужно, чтобы все изображения были одинаковые.
- `batch_size=16` — количество изображений в батче. Чем больше изображений, тем лучше обучится сеть. Много фотографий в памяти GPU не поместится, поэтому 16 — это золотая середина, с которой можно стартовать.
- `class_mode='sparse'` — аргумент, который указывает тип выдачи метки классов. `sparse` (англ. «редкий») означает, что метки будут порядковым номером папки.

  Узнать, как номера классов связаны с названиями папок, можно так:

  ```
  # англ. индексы классов
  print(datagen_flow.class_indices)
  ```

Применив метод `datagen.flow_from_directory(...)`, получим объект, у которого пары «картинки — метки» можно получить функцией *next()* (англ.

«следующий»):

```
features, target = next(datagen_flow)

print(features.shape)
```

Получили признаки — четырёхмерный тензор, в котором 16 изображений размером 150×150 с тремя цветовыми каналами.

Чтобы обучить на этих данных модель, передадим объект `datagen_flow` в метод *fit()*. Эпоха не должна быть бесконечно длинной. Для этого укажем в параметре `steps_per_epoch` количество батчей в наборе данных:

```
model.fit(datagen_flow, steps_per_epoch=len(datagen_flow))
```

В методе *fit()* должна быть не только обучающая, но и валидационная выборка. Для этого создайте два загрузчика: для обучающей и валидационной.

```
# указываем загрузчику, что валидация содержит
# 25% случайных объектов
datagen = ImageDataGenerator(validation_split=0.25)

train_datagen_flow = datagen.flow_from_directory(
    '/datasets/fruits_small/',
    target_size=(150, 150),
    batch_size=16,
    class_mode='sparse',
    # указываем, что это загрузчик для обучающей выборки
    subset='training',
    seed=12345)

val_datagen_flow = datagen.flow_from_directory(
    '/datasets/fruits_small/',
    target_size=(150, 150),
    batch_size=16,
    class_mode='sparse',
    # указываем, что это загрузчик для валидационной выборки
    subset='validation',
    seed=12345)
```

Теперь обучение запускается так:

```
model.fit(train_datagen_flow,
          validation_data=val_datagen_flow,
          steps_per_epoch=len(train_datagen_flow),
          validation_steps=len(val_datagen_flow))
```

Аугментации

Если обучающих примеров мало, сеть может переобучиться. Чтобы увеличить датасет, применяют аугментацию. **Аугментация** (англ. *augmentation*) — увеличение объёма данных через трансформацию существующего датасета. Причём меняется только обучающая выборка, тестовая и валидационная остаются прежними.

Суть техники заключается в преобразовании исходного изображения, но с сохранением его целевого признака. Например, изображение можно повернуть или отразить.

Аугментации бывают такие:

- поворот,
- отражение,
- изменение яркости и контрастности,
- растягивание и сжатие,
- размытие и повышение чёткости,
- добавление шума.

К одному изображению можно применить сразу несколько типов аугментаций.

При аугментации можно столкнуться с рядом проблем. Например, поменяется класс изображения или получится не фотография, а картина в стиле абстрактного импрессионизма. От этого пострадает качество модели.

Проблем можно избежать, если следовать этим рекомендациям:

- Не применяйте аугментацию на валидационной и тестовой выборках, чтобы не искажать значения метрик.

- Не запускайте сразу все аугментации: добавляйте по одной и следите за изменением метрики качества на валидационном наборе.
- Всегда оставляйте часть изображений в данных без изменений.

Аугментации в Keras

В *ImageDataGenerator* есть опции для добавления аугментаций. По умолчанию они отключены. Допустим, применим отражения по вертикали (англ. *vertical flip*):

```
datagen = ImageDataGenerator(validation_split=0.25,
                             rescale=1./255,
                             vertical_flip=True)
```

Для обучающей и валидационной выборок нужно создать разные генераторы:

```
train_datagen = ImageDataGenerator(
    validation_split=0.25,
    rescale=1./255,
    horizontal_flip=True)

validation_datagen = ImageDataGenerator(
    validation_split=0.25,
    rescale=1./255)

train_datagen_flow = train_datagen.flow_from_directory(
    '/dataset/',
    target_size=(150, 150),
    batch_size=16,
    class_mode='sparse',
    subset='training',
    seed=12345)

val_datagen_flow = validation_datagen.flow_from_directory(
    '/dataset/',
    target_size=(150, 150),
    batch_size=16,
    class_mode='sparse',
    subset='validation',
    seed=12345)
```

Чтобы обучающая и валидационная выборки не содержали общих элементов, задайте объектам *train_datagen_flow* и *val_datagen_flow*

одинаковое значение `seed`.

ResNet в Keras

Импортируем *ResNet* из *Keras*. 50 означает количество слоёв в сети.

```
from tensorflow.keras.applications.resnet import ResNet50

model = ResNet50(input_shape=None,
                 classes=1000,
                 include_top=True,
                 weights='imagenet')
```

Рассмотрим все аргументы:

- `input_shape` — размер входного изображения. Например: `(640, 480, 3)`.
- `classes=1000` — количество нейронов в последнем полносвязном слое, в котором выполняется классификация.
- `weights='imagenet'` (от англ. «сеть изображений») — инициализация весов. *ImageNet* — название большого датасета, на котором сеть обучалась классифицировать изображения на 1000 классов. Если обучение сети начать на *ImageNet*, а продолжить на вашей задаче, результат будет лучше, чем если обучать с нуля. Чтобы инициализация весов была случайной, напишите `weights=None`.
- `include_top=True` (англ. «добавить верхушку») — указание на то, что в конце архитектуры *ResNet* есть два слоя: *GlobalAveragePooling2D* и *Dense*. Если задать *False*, то этих слоёв не будет.

Рассмотрим последние слои:

1. *GlobalAveragePooling2D* (англ. «глобальный двумерный пулинг усреднением») — пулинг с окном во весь тензор. Как и *AveragePooling2D,* возвращает среднее значение из группы пикселей внутри канала. *GlobalAveragePooling2D* нужен, чтобы усреднить информацию по всему изображению, то есть получить пиксель с большим количеством каналов (например, 512 для *ResNet50)*.

2. *Dense* — полносвязный слой для классификации.

Разберём, как применять предобученную на *ImageNet* сеть. Чтобы адаптировать *ResNet50* к нашей задаче, уберём верхушку и сконструируем

её заново:

```
from tensorflow.keras.layers import GlobalAveragePooling2D, Dense
from tensorflow.keras.models import Sequential

backbone = ResNet50(input_shape=(150, 150, 3),
                    weights='imagenet',
                    include_top=False)

model = Sequential()
model.add(backbone)
model.add(GlobalAveragePooling2D())
model.add(Dense(12, activation='softmax'))
```

где `backbone` (англ. «костяк») — то, что осталось от *ResNet50*.

Научим вас трюку. Допустим, есть очень маленький датасет: всего 100 картинок и два класса. Если на таком датасете обучить *ResNet50*, то она гарантированно переобучится: в ней слишком много параметров — порядка 23 млн! У сети будут идеальные предсказания на обучающей выборке и случайные — на тестовой.

Чтобы этого избежать, «заморозим» часть сети: некоторые слои оставим с весами из *ImageNet*, они не будут обучаться градиентным спуском. Обучим только 1–2 полносвязных слоя наверху сети. Так количество параметров в сети уменьшится, но архитектура сохранится.

Заморозим сеть так:

```
backbone = ResNet50(input_shape=(150, 150, 3),
                    weights='imagenet',
                    include_top=False)

# замораживаем ResNet50 без верхушки
backbone.trainable = False

model = Sequential()
model.add(backbone)
model.add(GlobalAveragePooling2D())
model.add(Dense(12, activation='softmax'))
```

Чтобы сеть обучалась, добавленный сверху *backbone* полносвязный слой замораживать не стали.

Заморозка позволяет избавиться от переобучения и повысить скорость обучения сети: градиентному спуску считать производные для замороженных слоёв не нужно.