

Конспект по теме "Анализ алгоритмов"

Вычислительная сложность

Время работы алгоритма не измеряют в секундах, оно определяется количеством выполняемых алгоритмом элементарных операций: сложений, умножений и сравнений. Когда говорят о времени работы на определённом компьютере, обычно его называют **реальным временем работы**. На время работы алгоритма также влияют его аргументы.

Время работы сложных алгоритмов вычислить нельзя. Поэтому рассчитывают их **вычислительную сложность**, или **асимптотическое время работы** — от слова **асимптота** — прямая, к которой кривая приближается, но не может её пересечь.

Обозначим длину входных данных n . Время работы — это функция от n , то есть $T(n)$. Асимптотическое время работы алгоритма показывает, как растёт $T(n)$ при увеличении n .

Когда $T(n)$ — это многочлен, то асимптотическое время работы равно одночлену наибольшей степени без коэффициента (например, n^2 вместо $5n^2$). При больших значениях n остальные одночлены не важны.

- Если $T(n) = 4n + 3$, асимптотическое время работы $T(n) \sim n$. У алгоритма **линейная сложность**.
- Если $T(n) = 5n^2 + 3n - 1$, асимптотическое время работы $T(n) \sim n^2$. У алгоритма **квадратичная сложность**.
- Если $T(n) = 10n^3 - 2n^2 + 5$, то $T(n) \sim n^3$. У алгоритма **кубическая сложность**.
- Если $T(n) = 10$, то $T(n) \sim 1$. У алгоритма **константная сложность**, то есть не зависит от n .

Время обучения линейной регрессии

Задача обучения линейной регрессии такая:

$$w = \arg \min_w \text{MSE}(Xw, y)$$

Веса вычисляются по формуле:

$$w = (X^T X)^{-1} X^T y$$

Найдём вычислительную сложность расчёта весов, но прежде:

- Обозначим количество объектов в обучающей выборке как n , а количество признаков — p ;
- Размер матрицы X будет $n \times p$, размер вектора y — n ;
- Обозначим вычислительную сложность как $T(n, p)$, поскольку она зависит от двух параметров: n и p .

Тогда вычислительная сложность обучения линейной регрессии будет $T(n, p) \sim np^2 + p^3 + np^2 + np$

Признаков обычно меньше, чем объектов, то есть $p < n$. Умножим обе части на p^2 , получим $p^3 < np^2$. Оставим только одночлен наибольшей степени и получим: $T(n, p) \sim np^2$. Если признаков много, модель будет обучаться долго.

Итеративные методы

Задача решается **прямым методом**, когда модель линейной регрессии обучается по такой формуле:

$$w = (X^T X)^{-1} X^T y$$

Прямые методы помогают найти точное решение по заданной формуле или алгоритму. Их вычислительная сложность не зависит от данных.

Другой подход к обучению модели линейной регрессии — **итеративный метод**, или **итеративный алгоритм**. Он не даёт точного решения, только приближённое. Алгоритм многократно выполняет похожие итерации, на каждом шаге решение становится всё точнее. Если слишком большая точность не нужна, хватит и небольшого числа итераций.

Вычислительная сложность итеративных методов зависит от числа шагов, на которое может влиять и содержание данных.

Метод бисекции

Итеративным методом найдём решение уравнения $f(x) = 0$. Пусть $f(x)$ — **непрерывная функция**, то есть график такой функции можно нарисовать, не отрывая карандаша от бумаги.

Решить уравнение поможет **метод бисекции**. На вход он принимает непрерывную функцию и отрезок $[a, b]$. У значений $f(a)$ и $f(b)$ разные знаки.

Когда эти два условия выполняются:

1. функция непрерывна,
 2. у значений на концах отрезка знаки разные,
- то корень уравнения где-то на отрезке.

На каждой итерации метод бисекции:

- Проверяет, равно ли нулю любое значение $f(a)$ или $f(b)$. Если равно, то решение найдено;
- Находит середину отрезка $c = (a + b) / 2$;
- Сравнивает знак $f(c)$ со знаками $f(a)$ и $f(b)$:
 - Если у $f(c)$ и $f(a)$ разные знаки, то корень обязательно есть на отрезке $[a, c]$. К этому отрезку и переходит алгоритм на следующей итерации;
 - Если у $f(c)$ и $f(b)$ разные знаки, то корень обязательно есть на отрезке $[b, c]$. К нему переходит алгоритм на следующей итерации;

- Знаки $f(a)$ и $f(b)$ разные, поэтому других вариантов быть не может.

Обычно заранее выбирают точность решения, например, $\epsilon = 0.000001$. На каждой итерации отрезок с корнем уменьшается в два раза. Если получаем длину отрезка меньше ϵ , работу алгоритма можно остановить. Такое условие называется **условием остановки**.

Сравнение методов

Большая часть этого курса посвящена ключевому для машинного обучения итеративному методу — **градиентному спуску** (англ. *gradient descent*). На нём построено много алгоритмов обучения.

Обозначим его преимущества перед прямыми методами:

```
Choose randomly  $x_0$ 
While  $\|f'(x_{n-1}) - f'(x_n)\| > \epsilon$  do
  Choose a decreasing  $\gamma_n$  (generally  $1/n$ )
  Compute  $x_{n+1} = x_n - \gamma_n \nabla f(x_n)$ 
End while
Do some random restarts
Return the lowest couple  $x_n, f(x_n)$  found.
```

- Для линейной регрессии с функцией потерь MSE он работает быстрее на больших наборах данных.
- Градиентный спуск годится для линейной регрессии и с другими функциями потерь (не для всех есть формулы).
- Он применим в обучении нейронных сетей, для которых тоже нет прямой формулы.